

UBION 디지털 금융 전문가 과정 PROJECT_1 최종발표

은행거래데이터를 활용한 이상거래 탐지 성능 개선 연구

팀명 : 삭스핀 (Shark's fin)

팀원 :김지훈, 박승주, 신성윤, 이선주, 이의섭, 임재환

목차

1. 팀명 및 팀원 소개

2. 이상거래란?

3. 주제 선정이유

4. 데이터 설명

5. 중간발표 정리

6. 개선 과정

7. 유형별 특징 정리

8. 한계점 및 시사점

01

팀명 및 팀원 소개

' Shark's fin '

: Shocks + fin

상어가 fishing을 방해하듯이, 금융 시장의 충격들을 방지하는 목적을 가짐



01 팀명 및 팀원 소개

김지훈

데이터 전처리
모델링

신성운

데이터 전처리
모델링



박승주

데이터 전처리
Feature 선정
방향성 제시

이선주

데이터 전처리
방향성 제시
PT 자료 생성

이의섭

데이터 전처리
모델링


임재환

데이터 전처리
모델링

02 이상거래란 ?

02 이상거래란 ?

이상거래 : 고객의 의사에 반하거나, 정상적인 거래 패턴에서 벗어난 비정상적인 거래 행위



02 이상거래란 ?

“ **FDS (이상거래 탐지 시스템)** ”

: 'Fraud Detection System'의 준말


거래 내역, 고객 정보, 평소 거래 패턴 등을 분석해서 의심되는 이상 거래를 탐지하고 차단하는 기술

수집 데이터 예시

고객정보



금융거래정보



접속기기정보

Big Data

수집된 데이터를 거래 유형,
이용자 유형별 상관관계 등 분석하여
이상금융 거래행위 분석 수행

대응예시

고객대상 통화확인



임시 거래중지



사전포착

03

주제 선정이유

03 주제 선정이유

주제 선정이유 1

이상거래로 인한 고객들의 피해 건수 증가

금융사들의 이상거래 탐지 시스템
구축 및 개발에 대한 관심 증가

“

금융권 취업을 준비함에 있어 해당 이상거래 데이터를 다뤄보는 경험의 필요성 인식

”

금융사의 이상거래 탐지 시스템 구축 및 개발 중요성 증가

03 주제 선정이유

한계점?

“ 이상거래 데이터 수집의 어려움 ”



개인정보가 포함되었기에
현직자가 아니면 접근이 용이하지 않음



FSI AIXData Challenge 2024

알고리즘 | 금융보안원 | 생성형 AI | 생성 | 정형 | 분류 | Macro F1 Score | TCAP

₩ 상금 : 1,700 만원

🕒 2024.08.05 ~ 2024.08.30 09:59 [+ Google Calendar](#)

👤 576명 📅 마감

데이콘 <이상거래 탐지 AI> 데이터 활용

주관: 금융보안원

후원: KB국민은행, 하나은행, 미래에셋, 금융위원회

금융보안원이 제공하는 가상데이터를 활용



“ 데이터를 역으로 분석
이상거래 유형별 특성에 대한 인사이트 도출 ”

03 주제 선정이유

주제 선정이유 2

한계점?

실제 데이터 접근이 어렵다는 한계는 있지만,
가상 데이터를 통해 이상거래 탐지 모델에 대한 경험을 쌓을 수 있음



이후 실무에서 데이터 접근이 가능해졌을 때
해당 경험이 업무에 기반 지식으로 쌓임

“ 질 나쁜 식재료라도 조리법을 익히고, 질 좋은 재료가 준비되었을 때 시행착오를 줄인다. ”

현직자가 아니면 접근이 용이하지 않음

“ 데이터를 역으로 분석
이상거래 유형별 특성에 대한 인사이트 도출 ”

04

데이터 설명

04 데이터 설명

데이터 설명

120,000개 (불균형 데이터)

A ~ L : 1,200개(각 100개)

M : 118,800개

- 데이터 유형 -

이상거래 : A ~ L
정상거래 : M

범주형: 49

수치형: 15

- 총 컬럼의 수 -

64개

- 점수 채점 기준 -

TCAP (30%)

+


MACRO F1 SCORE
(70%)

05

중간발표 정리

05 중간발표 정리

WORK FLOW



첫 번째 시도


- 1. 합성 데이터: **CTGAN** 사용해서 생성
- 2. 범주형 변수: **라벨 인코딩** 사용

Score : **0.5365980846**

인사이트	개선 방향성
EDA 및 논문 (이상거래 패턴 관련)	파생변수 생성 및 컬럼 제거 필요성 인지

05 중간발표 정리

WORK FLOW



두 번째 시도

- 1. 파생변수생성 : 직전 거리와 먼 거리 차이
잔액 소진 여부 등
- 2. 컬럼 제거: 고유값 및 상수값

Score : 0.5822849987

인사이트	개선 방향성
파생변수와 컬럼제거 : 점수향상의 한계 인지	모델 선정 및 하이퍼파라미터 조정

05 중간발표 정리

WORK FLOW

- 1 데이터 로드
- 2 합성 데이터 생성
및
원본 데이터 병합
- 3 파생변수 생성 및 컬럼 제거
- 4 인코딩
- 5 모델링

EDA 및 논문 인사이트 → “파생변수 생성”

----- 예시 -----

A_Is_Large_Distance
A_VPN_and_Large_Distance
B_Flag_GradeC_DeviceAnomaly
D_Scripted_Like_Transaction
E_Vishing_Withdrawal_Risk
F_Is_Sudden_Balance_Drop

...


모델에 영향을 끼친 피처 중요도 확인
다음 모델링 파생변수 사용 여부 결정

05 중간발표 정리

WORK FLOW

- ① 데이터 로드
- ② 합성 데이터 생성
및
원본 데이터 병합
- ③ 파생변수 생성 및 컬럼 제거
- ④ 인코딩
- ⑤ 모델링

< EDA 인사이트 기반 생성 파생 변수 >



“ A_Is_Large_Distance ”


05 중간발표 정리

WORK FLOW

- ① 데이터 로드
- ② 합성 데이터 생성
및
원본 데이터 병합
- ③ 파생변수 생성 및 컬럼 제거
- ④ 인코딩
- ⑤ 모델링

< 논문 인사이트 기반 생성 파생변수 >


잔액 소진 여부 (잔액이 10% 이하)



“ F_Is_Sudden_Balance_Drop ”

05 중간발표 정리

WORK FLOW




< 컬럼 제거 >

고객명
주민번호
수취인 계좌번호
거래에 사용한 단말기 MAC주소
암호화된 계좌번호
거래에 사용한 단말기 IP주소
타 계좌 여부
거래 발생 위치
...

05 중간발표 정리

WORK FLOW



세 번째 시도

- 1. 모델 선정: XGBoost, CatBoost, LGBM
- 2. 앙상블 모델 사용



Score : 0.6181061990

인사이트	개선 방향성
12개유형을 한번에 모델링 ↓ 특성이 비슷한 유형 분류가 어려움	각 유형을 Targeting하는 이진분류 모델들을 앙상블 처리

05 중간발표 정리

WORK FLOW

- 1 데이터 로드
- 2 합성 데이터 생성
및
원본 데이터 병합
- 3 파생변수 생성 및 컬럼 제거
- 4 인코딩
- 5 모델링



05 중간발표 정리

한계점?

- ✓ 현 방식으로 목표 점수까지 올리기에 한계 (목표: 0.75)
- ✓ 13개의 유형(A~L, M:정상)을 중 E, F, G와 같이 특성이 비슷한 경우를 포착
- ✓ 12개 사기 유형 별 특징을 파악하기 어려운 유형 존재 (대표적으로 D 유형)

방향성 제시

13개의 유형을 각각 이진분류



모델들을 앙상블



13개 모델 각각의 피쳐중요도 확인



“ 최종목표인 사기 유형별 방지
인사이트 도출 ”

05 중간발표 정리

REMIND

FIRST

- 1. 합성 데이터: CTGAN 사용해서 생성
- 2. 범주형 변수: 라벨 인코딩 사용

Score : 0.5365980846

인사이트	개선 방향성
EDA 및 논문 (이상거래 패턴 관련)	파생변수 생성 및 컬럼 제거

SECOND

- 1. 파생변수생성 : 직전 거리와 먼 거리 차이
잔액 소진 여부 등
- 2. 컬럼 제거: 고유값 및 상수값

Score : 0.5822849987

인사이트	개선 방향성
변수 및 컬럼 외 방법 필요	모델 선정 및 하이퍼파라미터 조정

THIRD

- 1. 모델 선정: XGBoost, CatBoost, LGBM
- 2. 앙상블 모델 사용

Score : 0.6181061990

인사이트	개선 방향성
특성이 비슷한 유형 분류가 어려움	12개 유형을 Targeting하는 이진분류, 모델들을 앙상블 처리

05 중간발표 정리

POINT

목표점수

0.75 ↑

비슷한 유형 분류

E, F, G 유형

특징 파악 어려운
유형 존재

D 유형

Score : 0.5365980846

Score : 0.5822849987

Score : 0.6181061990

13개의 유형을 각각 이진분류

모델들을 앙상블


피처중요도 확인

“ 최종목표인 사기 유형별 특징 인사이트 도출 ”

06 개선 과정

06 개선 과정

WORK FLOW




첫 번째 시도

- (1. 유형 별 이진분류 실행
2. 각 모델 별 앙상블)

인사이트	개선 방향성
12종 분류하는 모델의 성능 개선 가능성	원본 데이터 및 생성 데이터
↓	
학습 시 원본 데이터와의 비율 중요	비율을 하나씩 대조하며 성능 평가

06 개선 과정

WORK FLOW




06 개선 과정


WORK



피쳐 중요도 및 성능 향상을 위한 시도



B ~ M(12개)
: A 개수에 맞춰 각 약 90개 추출



B ~ M(12개)
: A와 같은 비율(1100개씩)

“ 최적의 비율은 직접 시도가 필요 ”

06 개선 과정

WORD

피처 중요도 및 성능 향상을 위한 시도

①

입력 데이터

②

각 라벨 별 이진분류

Score : 0.62 ▶ 0.68

A vs Rest

B vs Rest

③

라벨 별 Soft voting
예측 확률 확

④

Soft voting 앙상블 및 평균


⑤

제출 파일 생성

2025-05-25 15:28:31

0.6842522425

0.68424968



B ~ M(12개)

수에 맞춰 각 약 90개 추출

~

M


B ~ M(12개)

: A와 같은 비율(1100개씩)

“ 최적의 비율은 직접 시도가 필요 ”

06 개선 과정

WORK FLOW



두 번째 시도

Threshold 조정 및 모델 학습에 사용 할
원본 데이터 및 생성 데이터 비율 하나씩 비교
최적의 비율 찾기

인사이트	개선 방향성
원본 : 생성 데이터가 1:1 비율일 때 고성능 확인	다양한 생성형 모델을 사용
↓ 생성 데이터의 질이 좋다면, 생성 과정과 익명성 평가에 집중	익명성 평가 시 수치형 변수에 Noise 넣고 중복값 줄이기

06 개선 과정



WORD

Soft voting 예측 확률예시
 $a=0.13, b=0.34, c=0.02\cdots$

가장 높은 확률의 라벨 찾기
(argmax: b, 0.34)

Threshold
0.2 이상인가?

예

B로 분류

아니오

M(정상거래)

최종 예측 라벨

06 개선 과정

WORK FLOW

①

입력 데이터

드 버퍼 시드

“ 원본 데이터(100개)에서 생성 데이터(1000개)를 만들어 학습시키는 것은 ”

과적합이지 않을까?

⑤

Soft voting 앙상블 및 평균

⑥

제출 파일 생성

1:2 비율일 때 고성능 확인



생성 데이터의 질이 좋다면,
생성 과정과 익명성 평가에 집중

익명성 평가 시
수치형 변수에 Noise 넣고
중복값 줄이기

06 개선 과정

WORK FLOW



1:1 비율에서 성능이 가장 우수

06 개선 과정

WORK FLOW

① 입력 데이터

② 각 라벨 별 이진분류 시행

Score : 0.68 ▶ 0.72

A vs Rest

B vs Rest

③ 라벨 별 Soft voting
예측 확률 확

④ Soft voting 앙상블 및 평균

⑤ 제출 파일 생성

2025-05-25 13:50:29

0.7229800875
0.7235838449



Best

1:10

1:5

1:2

1:1

1:0.5

1:1 비율에서 성능이 가장 우수

06 개선 과정

WORK FLOW

중복 없이 생성
(익명성)

수치형 변수에
Noise 추가

CTGAN

VAE

Forest
Diffusion

세 번째 시도

1. 다양한 생성 모델 성능 비교
2. 수치형 변수에 Noise 넣고 중복값 줄이기

인사이트

생성 데이터의 질을 높인다면
익명성 평가 부분과 학습 부분에서 성능이 오른다.

06 개선 과정

WORK FLOW

중복 없이 생성
(익명성)

수치형
Noise

CTGAN

VAE

Forest
Diffusion

'수취인 계좌번호' 컬럼의 중복 개수: 1543

▶ 중복 예시: ['GKKdmLIANT' 'IEFBWJYyVF' 'yAiJgLv0xN' '0mCGgBfDJP' 'bDNskPdUgo']

'암호화된 계좌번호' 컬럼의 중복 개수: 1632

▶ 중복 예시: ['FsMgcAKiNu' 'KnZBtkD001' 'TTDYVBtULp' 'lwLSrcKsWj' 'TOWlUYrfYt']

'거래에 사용한 단말기 IP주소' 컬럼의 중복 개수: 0

'주민번호' 컬럼의 중복 개수: 1622

▶ 중복 예시: ['MytyhN-OHnPWLP' 'kqNGQM-XKeQiQU' 'RJqGzs-qvaSEIm' 'UGXfnb-LCfKrsL' 'UXhaKw-xjkJBGo']

'거래에 사용한 단말기 MAC주소' 컬럼의 중복 개수: 0

'고객명' 컬럼의 중복 개수: 1894

▶ 중복 예시: ['한준혁' '송선영' '이재현' '홍현주' '민승민']

인사이트

생성 데이터의 질을 높인다면

익명성 평가 부분과 학습 부분에서 성능이 오른다.

06 개선 과정

WORK FLOW

 LLM 기반 민감정보 생성

n_rows = len(all_synthetic_data)

all_synthetic_data["고객명"] = generate_shuffled_llm_values("""13000개의 한국인 이름을 생성하세요. 각 이름은 2~5자이며 실존 인물처럼 결과는 쉼표(,) 또는 줄바꿈으로 구분하세요. 예: 김민수, 이지은, 박현우""", n_rows)

all_synthetic_data["주민번호"] = generate_shuffled_llm_values("""13000개의 랜덤 식별번호를 생성하세요. 각 번호는 '알파벳 6자리-알파벳 6자리' 형식 예: ABCDEF-GHIJKLM. 결과는 쉼표 또는 줄바꿈으로 구분하세요.""", n_rows)

all_synthetic_data["거래 발생 위치"] = generate_shuffled_llm_values("""서로 다른 13000개의 실제처럼 보이는 대한민국 내 주소를 생성하세요. 예: 서울시 강남구 34.123 127.456 결과는 쉼표 또는 줄바꿈으로 구분하세요.""", n_rows)

all_synthetic_data["암호화된 계좌번호"] = generate_shuffled_llm_values("""13000개의 랜덤 알파벳 10글자를 생성하세요. 'XXXXXXXXXX' 형식 예: pymitZwuNZ. 결과는 쉼표 또는 줄바꿈으로 구분하세요.""", n_rows)

all_synthetic_data["거래에 사용한 단말기 IP주소"] = generate_shuffled_llm_values("""13000개의 X.X.X.X 형식을 따르는 IP주소를 생성하세요.""", n_rows)

all_synthetic_data["거래에 사용한 단말기 MAC주소"] = generate_shuffled_llm_values("""13000개의 실제처럼 보이는 MAC 주소를 생성하세요.""", n_rows)

06 개선 과정

WORK FLOW

중복 없이 생성
(익명성)

수치형 변수에
Noise 추가

Score : 0.72 ▶ 0.75

세 번째 시도

1. 다양한 생성 모델 성능 비교

Noise 넣고 중복값 줄이기

CTGAN

VAN

Forest
Diffusion

2025-05-28 00:49:56


0.7515984824

0.7512006121

생성 데이터의 질을 높인다면

익명성 평가 부분과 학습 부분에서 성능이 오른다.

06 개선 과정



06 개선 과정

“ 여러 개선 과정을 거쳐
결국 중요한 것은 피처란 것을 파악

파생변수 생성 집중

파생변수 생성

모델링에 집중



06 개선 과정

WORK FLOW

- ① Score 정체
- ② 데이터 다시 분석
- ③ 모델링 집중
- ④ 파생변수 생성 중요성 파악

네 번째 시도

(파생변수 생성)

방향성


높은 성능을 보인 모델을 통해 피쳐 중요도를 확인

유형별 특징 정의

06 개선 과정


피쳐 중요도

LGBM 'c' 유형별 Feature Importance Top 10



피쳐 중요도

CatBoost 'e' 유형별 Feature Importance Top 10





06 개선 과정

피처 중요도

피처 중요도

“ C, D, G에 대한 파생변수를 찾으려 노력함 ”



06 개선 과정

모델 최종 성능

// Score : 0.8032545624 //

2025-05-28 10:36:17

0.8016382159
0.8032545624



1	hector21		0.82371
2	인형눈볼이기장인		0.81983
3	GNOEYHEAT		0.81802
4	GSDS		0.81756
5	KKYU		0.81028
6	BITAmin 12기		0.80137
7	장종원		0.79309

06 개선 과정

모델 최종 성능

// Score : 0.8032545624 //

2025-05-28 10:36:17

0.8016382159
0.8032545624

최종 6위 성적


1	hector21		0.82371
2	인형눈불이기장인		0.81983
3	GNOEYHEAT		0.81802
4	GSDS		0.81756
5	KKYU		0.81028
6	BITAmin 12기		0.80137
7	장종원		0.79309

07

유형별 특징 정리

07 유형 별 특징 정리


CatBoost 'a' 유형별 Feature Importance Top 10



A유형

직전 거래 발생지와의 거리 차이가 매우 크며,
짧은 시간 차이 내 연속적인 거래 발생.

CatBoost 'b' 유형별 Feature Importance Top 10




B유형

저축 계좌 비율 높음, 저신용 고객의 고액 이체 패턴 다수 발생.
VPN 사용, 탈옥 및 루팅, 로밍 등 비정상적 환경 사용 비율 높음.

07 유형 별 특징 정리


CatBoost 'c' 유형별 Feature Importance Top 10



C유형

ATM 채널 사용 비율 높음
키로킹 및 탬퍼링 비율 높음
거래 시스템 접속 실패 빈도 높음

CatBoost 'd' 유형별 Feature Importance Top 10




D유형

7일 거래내역 중 미사용 단말 여부 비율
특정 인증방식(ID/PW, 패턴)
에러코드(에러 없음)의 비율이 높음

07 유형 별 특징 정리


CatBoost 'e' 유형별 Feature Importance Top 10



E유형

거래 채널이 모두 ATM이며,
최근 7일 내 천만원 이상의 입금 내역에서 높은 비율

CatBoost 'f' 유형별 Feature Importance Top 10




F유형

거래 채널이 모두 Others(기타)
거래에 사용한 단말기 OS에서 Windows/Others
사용 비율이 높음

07 유형 별 특징 정리


CatBoost 'g' 유형별 Feature Importance Top 10



G유형

최근 30일 이내 계좌 정지 해제
7일 이내 1천만 원 이상 입금
출금(음수 이체) 비율이 높음

CatBoost 'h' 유형별 Feature Importance Top 10




H유형

평소 거래 한도 잔여액이 높고,
월간 최대 거래 금액은 낮은 상태에서 거래

07 유형 별 특징 정리


CatBoost 'I' 유형별 Feature Importance Top 10



I유형

소액(250만원 이하)을 반복적으로 시도
특히 새벽 시간대 이체 빈도 높음

CatBoost 'J' 유형별 Feature Importance Top 10




J유형

수취 계좌가 모두 7일 거래내역 중 미거래 및 거래 중지 계좌
3시간 이내 해당 수취계좌에 이체 횟수가 0회

07 유형 별 특징 정리

CatBoost 'k' 유형별 Feature Importance Top 10




K유형

동일 수취 계좌로 단시간(3시간 이내)
2회 이상 반복 이체 발생 비율이 높고,

7일 내 미거래 계좌 여부 모두 포함되지 않음 (자주 거래하는 계좌)

CatBoost 'l' 유형별 Feature Importance Top 10



L유형

고객이 고령층(60세 이상)에 집중

대출 관련 거래 빈번 발생 특히 담보 대출에서 큰 횟수

08

한계점 및 시사점

08 한계점 및 시사점

한계점

- ✓ 실제 데이터가 아닌 가상 데이터를 사용했기 때문에 실제 환경에서 적용가능한지 확인 미지수
- ✓ TCAP 채점 기준이 공개되지 않아 '익명성 평가'라는 부분의 모호함

08 한계점 및 시사점

시사점 1

이상거래 탐지를 통해

소수 클래스도
분명한 패턴이 존재함을 인지

시사점 2

유형 특징을 구분하기 위해서,

결국 EDA 인사이트를 통해
다양한 파생변수를
생성하는 것이 중요함을 인지

시사점 3

극심한 불균형 데이터 및
다중 분류 모델의

모델링 과정을 실습하며
프로세스를 이해

감사합니다.