



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

딥러닝을 이용한 전자금융이상거래 탐지 모델 수립

연세대학교 정보대학원
금융정보보호 전공
전 일 교

딥러닝을 이용한 전자금융이상거래 탐지 모델 수립

지도교수 김 희 응

이 논문을 석사 학위논문으로 제출함

2016년 12월 30일

연세대학교 정보대학원

금융정보보호 전공

전 일 교

전일교의 석사 학위논문을 인준함

심사위원 김 희 응



심사위원 이 중 정



심사위원 김 범 수



연세대학교 정보대학원

2016년 12월 30일

감사의 글

우선 논문을 지도해주신 김희웅 교수님께 감사합니다. 훌륭한 연구자로서의 교수님 모습을 보면서 많은 것을 느끼고 배울 수 있었습니다. 바쁘신 중에도 논문심사를 맡아주신 이중정, 김범수교수님께 감사합니다. 논문에 대한 유익한 말 씀과 충고가 많은 도움이 되었습니다.

2년 동안 함께 수학하며 많은 추억을 쌓아온 금융 정보보호과정 신동순, 강은성, 김성일, 김국현, 최상호, 강지은, 정귀영 학우들에게도 감사드립니다.

또한, 저에게 공부를 할 수 있도록 여러모로 지원하고 도움주신 직장 선배, 후배, 동료분들께도 깊은 감사를 드립니다.

2016년 12월

전 일 교

목 차

1. 서론	1
1.1. 연구 배경	1
1.2. 연구 목적 및 방법	3
1.3. 기존 문헌 연구	4
2. 이론적 배경	5
2.1. DNN	5
2.2. Cost Function	6
2.3. Activation Function	6
2.4. Optimizer	7
3. 1차 실험	8
3.1. 개요	8
3.2. 실험환경 구축	8
3.3. 실험 데이터 정의	9
3.4. DNN 설계	11
3.5. 모델 생성 및 검증	12
4. 2차 실험	15
4.1. 개요	15
4.2. 실험 데이터 정의	16
4.3. DNN 설계	16
4.4. 모델 생성 및 검증	17
5. 결론 및 시사점	19
참고문헌	21
영문요약	22

그림 차례

그림 1. FDS 시스템 개요	2
그림 2. 전자금융이상거래탐지 모델링 프로세스	9
그림 3. 전자금융이상거래탐지 모델 Topology	11
그림 4. DNN 알고리즘 프로그래밍.....	12
그림 5. 전자금융이상거래탐지 모델 검증결과	13
그림 6. 기존FDS탐지율과의 비교	14
그림 7. 전자금융이상거래탐지 모델 검증결과(2차 실험)	18

표 차례

표 1. 학습 데이터 변수	10
표 2. 학습 데이터 변수 (2차실험)	16

<국문요약>

딥러닝을 이용한 전자금융이상거래 탐지 모델 수립

2010년 이후 스마트폰뱅킹의 등장과 함께 전자금융 이용자 수는 지속적으로 증가해왔다. 국내 전자금융 환경이 짧은 시간 내에 발전함과 동시에 파밍, 피싱 등과 같은 전자금융 사기 또한 수법이 다양해지고 이용자 피해사고 또한 증가하였다. 이에 국내은행은 전자금융 이용자 보호를 위해 2014년도를 기점으로 전자금융이상거래탐지시스템(FDS)을 구축하고, 이용자로 로그 분석 기반의 이상거래 탐지 룰을 활용한 대응체계를 도입하게 되었다.

2015년도를 기점으로 국내 은행은 룰 기반의 FDS 탐지 체계 도입을 통해 전자금융 피해사고를 줄일 수 있었지만, 높은 오탐율로 인한 고객 불편 야기 및 룰을 우회하기 위한 시도들과 다양화되는 전자금융 사기에 능동적으로 대응하는데 한계를 보이고 있다.

본 논문에서는 이러한 한계를 개선하고자 머신러닝의 한 종류인 딥러닝 활용을 통해 높은 탐지율과 낮은 오탐율을 보이는 전자금융이상거래탐지 모델을 수립할 수 있음을 보였으며, 딥러닝에 사용되는 학습 데이터를 미래변화에 맞춘 조작을 통해 선제적인 모델을 수립하고 대응할 수 있음을 보임으로써 전자금융 보안체계를 업그레이드할 수 있는 방안을 제시하였다.

핵심되는 말 : FDS, 딥러닝, 전자금융사기, 이상거래탐지모델

1. 서 론

1.1. 연구 배경

2001년 인터넷뱅킹서비스의 시작과 2010년 스마트폰뱅킹서비스의 등장으로 전자금융 이용자의 수는 지속적으로 증가해 왔으며, 최근에는 90%의 은행거래가 비대면을 통해 이루어지고 있다.¹⁾ 이와 함께 보이스피싱과 악성코드 등을 통한 개인의 금융정보(공인인증서, 비밀번호 보안매체 정보 등) 탈취 및 자금의 불법 이체 사고 또한 함께 증가 추세를 보여 사회에 큰 문제로 대두되고 있다.


이에 2013년 7월 11일 금융위원회에서는 금융소비자 보호를 위해 ‘금융전산 보안강화 종합대책’을 발표 하여 국내 시중은행을 대상으로 FDS(Fraud Detect System)구축을 권고함으로써 비대면 채널에서 발생하는 불법이체 사고에 대한 모니터링 예방책을 마련하도록 하였으며, 그 이듬해인 2014년에 금융보안원을 통해 기술가이드를 제공하고, 2015년 국내 시중은행은 FDS시스템을 도입 및 운영하게 되었다.²⁾

최근에는 은행 뿐 아니라, 저축은행 등 제 2금융권까지 FDS도입이 확산되고 있으며, 카드사의 온라인 결제 시스템과 증권사 서비스에도 FDS가 도입되고 있다.

1) 뉴데일리 경제, <http://biz.newdaily.co.kr/news/article.html?no=10115101>

2) IT Chosun, <http://it.chosun.com/news/article.html?no=2797340>

[그림1]FDS 시스템 개요³⁾



현재 국내 시중은행에서 운영중인 FDS시스템은 [그림1]에서 보는 것과 같이 비대면 채널에서 이루어지는 거래 로그를 수집하고 분석하여 이상거래/정상거래 해당 여부를 판단하고 이상거래로 의심될 경우 추가인증(ARS, SMS) 또는 거래제한을 함으로써 사고를 예방할 수 있도록 운영 중에 있다.

하지만, 시스템을 운영함에 있어 노하우가 부족하고 사고거래 분석을 기반으로 한 시나리오 기반의 룰탐지 수준에 머무르고 있다. 룰기반의 탐지체계로도 개별 은행을 기준으로 70%의 높은 사고탐지율을 보이기도 하지만⁴⁾ 90% 이상의 오탐율 또한 보이고 있어⁵⁾, 고객의 불편과 정책 운영의 어려움을 초래하는 등 FDS시스템 운영의 한계가 지적되고 있다.

3) 금융보안원 '이상금융거래 탐지시스템 기술 가이드' 2014.08

4) 이투데이, <http://www.etoday.co.kr/news/section/newsview.php?idxno=1072404>

5) 컨슈머타임즈, <http://www.cstimes.com/news/articleView.html?idxno=168267>

시나리오 기반의 룰탐지의 경우 사고 시나리오 분석을 통해 룰을 도출함으로써 시나리오에 해당하는 사고를 타겟으로 하여 탐지하는 것에는 유용할 수 있으나, 정상거래의 분석이 함께 수반되지 못해 근본적으로 오탐율의 높을 수밖에 없다. 이러한 시나리오 기반의 룰탐지 체계의 한계를 벗어나기 위해서는 종합적인 위험요소에 대한 스코어링 방식이나 데이터마이닝 기법 등 통계적 수단을 활용하는 방안이 있을 수 있을 것이다.

이에 본논문에서는 최근 떠오르고 있는 기계학습 알고리즘인 DNN(Deep Neural Network)을 활용하여 정상거래로그와 사고거래로그를 지도학습 하고 높은 사고 탐지율과 낮은 오탐율을 달성할 수 있는 이상거래탐지 모델을 수립할 수 있음을 모델 구현과 검증을 통해 보이고자 한다.

1.2. 연구 목적 및 방법

본 논문에서는 최근 각광 받고 있는 DNN(Deep Neural Network) 알고리즘을 이용하여 감독학습(Supervised learning)을 통한 높은 탐지율과 낮은 오탐율을 보이는 전자금융이상거래탐지모델을 수립 및 검증 하고자 하였으며, 추가 연구를 통해 미래에 변화가 예상되는 전자금융 환경에 맞추어 선제적인 전자금융이상거래탐지 모델 수립에 DNN 알고리즘의 활용 방안을 연구하고자 한다.

이를 위해, 본 논문에서는 1차와 2차로 연구를 나누어 진행하였으며 1차 연구에서는 2016년도 전자금융 피해사고가 발생한 전자금융 이용자의 거래로

그 2년치 데이터를 수집하여 이용자별 프로파일링 분석을 통해 데이터를 전처리한 후 학습의 input data로 활용하고 output data로 정상거래/사고거래 구분 값을 입력하여 DNN을 통한 모델을 생성 및 검증 하였으며, 2차 연구에서는 예상되는 미래의 전자금융환경에 맞게 1차 실험에 사용되었던 학습데이터를 가공하여 1차와 마찬가지로 DNN을 통한 모델을 생성 및 검증을 수행하였다.

1.3. 기존 문헌 연구

신용카드 부정사용이나 보험사기와 같은 사기예방을 위한 탐지모델은 국내외에 활발히 연구되어왔다. Sanjeev Jha(2012)는 신용카드 사용습관 데이터를 기반으로 로지스틱 회귀분석을 통한 분류모델을 수립하고 신용카드 부정사용 거래를 기준으로 83%의 정탐율과, 3%의 오탐율을 보이기도 하였다.

하지만, 국내 은행의 FDS 도입은 비교적 최근에 이루어져 해당 연구가 많이 이루어지지 못하고 있다. 대다수 연구가 이상거래탐지 시스템 구축 방향과 관련한 내용을 이루고 있으며(최의순, 2015; 장재환, 2012;), 10개 내외의 입력변수를 활용한 의사결정나무 등의 데이터마이닝 기법을 활용한 연구가 주를 이루고 있다(박재훈, 2014).

2. 이론적 배경

2.1. DNN

심층신경망(DNN)은 입력층과 출력층 사이에 여러 개의 은닉층들로 이루어진 인공신경망(ANN)의 한 형태이다. 딥러닝은 앞먹임신경망(Feed forward network)의 형태를 취하며, 입력층부터 은닉층을 거쳐 출력층에 이르기 까지 이전 층(Layer)에서의 결과값(입력층의 경우 입력 값)이 활성화 함수(Activation function)을 통해 다음 층(Layer)에 전달되는 구조를 가지고 있다.

각 층에서 학습된 결과는 비용함수(Cost function)를 통해 오차를 계산하며, 오차를 줄이기 위한 방안으로 오차에서부터 거꾸로 계산하는 역전파(backpropagation) 방법을 통해 오차를 감소(gradient descent)시키며 학습하게 된다.

하지만, 은닉층(Hidden layer)이 깊어질 수록 깊은 층까지의 오차가 제대로 반영되지 못하는 기울기 소실문제(gradient Vanishing)가 발생하게 된다. 이는 활성화 함수의 미분값이 최대 값이 0으로 제한되어 있고 양쪽 끝에서 '0'으로 수렴하는 현상 때문이며, 최근에는 이를 해결한 Rectifier함수(Relu fuction)가 많이 사용되고 있다.

학습한 모델을 실제 적용하였을 때 오차가 큰 경우가 발생하기도 하는데 이는 너무 깊은 학습으로 모델의 일반화(Regularization)에 실패한 결과 과적합

(Over fitting)으로 인한 문제이며, 최근에는 과적합 문제를 해결하기 위해 인풋 레이어의 일부 뉴런의 일정 비율을 랜덤하게 배제하는 방법(Drop-out)을 통해 과적합 문제를 개선할 수 있음을 보이고 있다(Nitish Srivastava, Geoffrey Hinton, 2014).

2.2. Cost Function

딥러닝 모델에서 변수(parameters)를 최적화하는 것은 비용함수(Cost Function)를 최소화 하는 것과 연관 있다. 일반적으로 많이 쓰이는 비용함수에는 MSE(Mean Squared Error)와 CE(Cross Entropy) 방법이 있으며, CE함수를 비용함수로 사용하는 경우 MSE에 비하여 지역 최적화(local optimum)에 더 뛰어난 성능을 보인다고 밝힌 바 있다(Golik, 2013). 본 논문에서 또한 비용함수로 Cross Entropy를 통해 변수 최적화에 적용하도록 모델을 구현 하였다.

2.3. Activation Function

신경망을 구성하는 유닛의 출력 값은 활성화 함수(Activation Function)의 결과 값으로 출력이 된다. 활성화 함수는 유닛에 입력되는 입력 값과 가중치 값을 더한 값을 비선형 함수 변환을 통해 유닛의 활성화 정도(확률)를 산출하는데 사용된다. 본 논문에서는 활성화함수로 ReLU(Rectified Linear Unit)을 적용하여 모델을 구현하였다.

2.4. Optimizer

변수 최적화(parameter optimization)에 주로 쓰이는 기법은 경사 하강법 (gradient descent method)이다. 경사하강법은 학습이 반복될 수록 변수의 가중치를 조금씩 조정해가며 변수를 최적화 하는 기법이다. 그 중에서도 확률적 경사하강법(Stochastic Gradient Descent)은 샘플 기반의 경사 하강법을 통해 국지적 최적화를 피할 수 있는 방법으로 가장 널리 사용되고 있다. 본 논문에서는 최근에 뛰어난 성능을 보이고 있는 확률적 경사하강법에서 파생된 Adam(Diederik P. Kingma, Diederik P. Kingma, 2013) 을 모델에 적용하여 구현하였다.

3. 1차 실험

3.1. 개 요


1차 실험에서는 2016년도 전자금융사고 피해고객 113명의 과거 2년치 거래 Raw데이터를 수집한 후, 매 이체거래 마다 과거 1년치 거래에 대한 사용자의 전자금융 이용환경(OS환경, 네트워크환경), 거래성향(거래시각, 거래패턴 등)에 대해 프로파일링 분석을 통해 Raw 데이터를 Featured 데이터로 전처리 하고 이를 DNN의 학습데이터 중 input 데이터로 활용 하여 다양한 Topology를 모델링하고 검증하는 것으로 실험을 진행 하였다.

3.2. 실험환경 구축

DNN 학습을 위한 Raw data는 FDS Data Mart로부터 식별정보를 제외한 후 local database에 수집 및 구축하였고, 이체거래를 기준으로 과거 1년간의 거래를 프로파일링 분석을 통해 전처리 하여 학습데이터를 구축하였다.

DNN 모델 학습을 위하 리눅스 기반 위에 오픈소스 딥러닝 라이브러리인 Keras, Theano, Tesorflow를 구축하고 Python IDE를 구축하여 딥러닝 모델을 학습 및 검증할 수 있도록 실험 환경을 구축하였다(그림 2).

[그림2] 전자금융이상거래탐지 모델링 프로세스



3.3. 실험 데이터 정의

분석대상 데이터는 2016년 1월부터 9월 사이에 피싱, 파밍 또는 악성코드에 의해 금융거래정보를 탈취 당하여 전자금융이체사고 피해를 본 인터넷뱅킹 사용자 113명의 과거 2년치 전자금융거래로그 27,998건을 대상으로 하였다. 27,998건 거래로그 중 이체거래로그 5,292건의 거래로그를 정상거래로그(5,163건)와 사고거래로그(129건)로 분류하여 학습 데이터의 기준으로 삼았으며, 나머지 22,706건의 데이터는 로그인 거래로그 또는 이용기기저정이나 연락처정보 변경과 같은 사고와 연관된 거래로그로써 프로파일링 분석을 통한 데이터 전처리 후 이체거래로그와 함께 학습의 input 변수로 활용하였다.

학습 데이터는 과거 1년 동안 전자금융 거래에 사용한 단말환경/네트워크 환경/거래시각/이체거래패턴 등을 프로파일링 분석을 통한 26가지 변수와 현재 이체거래와 관련한 단말환경/네트워크환경/이체거래패턴 변수 16가지를 더 하여 총 42개의 변수를 학습의 input 변수로 활용하였다.

[표1] 학습 데이터 변수


Input 학습데이터 변수 정의				Output 변수 정의	
No.	변수명	No.	변수명	No.	변수명
1	int_device_cnt	15	night_trans_cnt	29	os_window
2	smt_device_cnt	16	nat_ip_cnt	30	os_none
3	ios_login_days	17	cn_login_days	31	china_ip_tf
4	ipad_login_days	18	abroad_login_days	32	new_ip_tf
5	android_login_days	19	vpn_login_days	33	log_vpn_tf
6	window_login_days	20	proxy_login_days	34	log_proxy_tf
7	etc_login_days	21	card	35	multi_transfer_tf
8	non_login_days	22	otp	36	new_acc_tf
9	vm_login_days	23	new_device_tf	37	today_same_acc_tcnt
10	total_trans_cnt	24	device_login_days	38	today_same_acc_tamt
11	total_trans_amt	25	nondevice_tf	39	night_tf
12	total_trans_days	26	vm_tf	40	select_device_tf
13	multi_trans_tf	27	os_ipad	41	modify_info_tf
14	transfer_account_cnt	28	os_ios	42	transfer_amt

전자금융사고 해당 유무
(유=1, 무=0)를 정의

3.4. DNN 설계

DNN의 설계는 3가지 서로 다른 형태의 Topology로 설계하였으며 은닉층 (Hidden layer)의 깊이는 3depth를 넘지 않도록 설계하였다(그림3).


[그림3]전자금융이상거래탐지 모델 Topology



DNN설계 시 Python2.7 개발환경에 Theano 기반 위에 Keras 라이브러리를 활용하여 구성하였으며, Hidden layer에서의 활성화 함수는 Relu를 적용하였으며 Output layer에서는 sigmoid를 적용함으로써 사고거래(1), 정상거래(0)을 학습하도록 설계 하였다. DNN의 비용함수로는 crossentropy를, 최적화 알고리즘으로는 Adam을 적용하였다(그림4).

학습 시 batch size와 학습 횟수 조정을 통해 여러 번 시도 하여 모델의 정확도를 비교하였으며, batch size는 10, 학습횟수가 40회일 때 정확도가 가장 높은 것으로 나타났다.

[그림4]DNN 알고리즘 프로그래밍



```

File Edit View Navigate Code Refactor Run Tools VCS Window Help
test_1 test_2.py test_2
test_3.py tmp.py test_2.py
25 for tmp in range(0, len(Y_1)):
26     if Y_1[tmp] == 1:
27         fraud_dataX.append(X_1[tmp])
28     else:
29         normal_dataX.append(X_1[tmp])
30 model = Sequential()
31 #model.add(Dropout(0.2, input_shape=(42,)))
32 model.add(Dense(42, input_dim=42, init='uniform', activation='relu'))
33 model.add(Dense(21, init='uniform', activation='relu'))
34 model.add(Dense(21, init='uniform', activation='relu'))
35 model.add(Dense(1, init='uniform', activation='sigmoid'))
36 model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
37 model.fit(X, Y, nb_epoch=40, batch_size=10, verbose=1)
38 score = model.evaluate(X, Y, verbose=1)

Run test_2
Epoch 31/40
4000/4000 [=====] - 1s - loss: 0.0055 - acc: 0.9980
Epoch 32/40
4000/4000 [=====] - 1s - loss: 0.0053 - acc: 0.9982
Epoch 33/40
4000/4000 [=====] - 2s - loss: 0.0055 - acc: 0.9982
Epoch 34/40
4000/4000 [=====] - 2s - loss: 0.0046 - acc: 0.9985
Epoch 35/40
4000/4000 [=====] - 4s - loss: 0.0047 - acc: 0.9982
Epoch 36/40
4000/4000 [=====] - 3s - loss: 0.0064 - acc: 0.9972
Epoch 37/40
4000/4000 [=====] - 2s - loss: 0.0054 - acc: 0.9980
Epoch 38/40
2910/4000 [=====>.....] - ETA: 0s - loss: 0.0052 - acc: 0.9979
78.82 LF: UTF-8
  
```

3.5. 모델 생성 및 검증

학습데이터 5,292건 중 4,000건의 데이터를 모델을 학습하는데 사용하였으며, 학습데이터 4,000건 중 102건은 사고거래 로그 데이터, 3,898건은 정상거래 로그 데이터로 구성하였다. 나머지 1,292건의 데이터는 모델을 검증하는데 사용하였으며, 검증데이터 1,292건 중 27건은 사고거래 로그 데이터, 1,265건은 정상거래 로그 데이터로 구성하였다.

이상거래탐지모델의 효과성 검증을 위해 학습데이터로 생성된 모델에 학습에서 제외되었던 검증데이터 1,292을 대입하여 사고거래 27건 중 몇 건을 사

고거래로 판단하는지(사고거래 탐지율)와 정상거래 중 몇 건을 사고거래로 잘못 탐지하는지(오탐율)를 측정하여 기존 룰 기반의 FDS와 비교하였다.

모델1, 모델2, 모델3에 각각 학습데이터를 40회 학습시킨 후 검증데이터를 대입하여 사고거래와 정상거래를 분류한 결과 모델1에서는 27건의 사고거래 중 26건을 탐지하여 96%의 탐지율을 달성하였으며, 정상거래 1,265건 중 9건을 사고거래로 탐지하여 0.71%의 오탐율을 보였다. 모델2에서는 27건의 사고거래 중 25건을 탐지하여 92%의 탐지율을 달성하였으며, 정상거래 1,265건 중 6건을 사고거래로 탐지하여 0.47%의 오탐율을 보였다. 모델3에서는 27건의 사고거래 중 25건을 탐지하여 92%의 탐지율을 달성하였으며, 정상거래 1,265건 중 9건을 사고거래로 탐지하여 0.71%의 오탐율을 보였다(그림5).


[그림5]전자금융이상거래탐지 모델 검증결과

모델 1 검증결과	모델 2 검증결과	모델 3 검증결과
학습횟수 : 40회 batch_size : 10 사고탐지율 : 27건 중 26건 탐지 (96%) 사고오탐지율 : 1265건 9건 오탐 (0.71%) Total fraud count : 27 Detect fraud count : 26 Percent of Detect fraud from total fraud : 96.00% Total normal count : 1265 Detect fraud count : 9 Percent of Detect fraud from total normal : 0.71%	학습횟수 : 40회 batch_size : 10 사고탐지율 : 27건 중 25건 탐지 (92%) 사고오탐지율 : 1265건 6건 오탐 (0.47%) Total fraud count : 27 Detect fraud count : 25 Percent of Detect fraud from total fraud : 92.00% Total normal count : 1265 Detect fraud count : 6 Percent of Detect fraud from total normal : 0.47%	학습횟수 : 40회 batch_size : 10 사고탐지율 : 27건 중 25건 탐지 (92%) 사고오탐지율 : 1265건 9건 오탐 (0.71%) Total fraud count : 27 Detect fraud count : 25 Percent of Detect fraud from total fraud : 92.00% Total normal count : 1265 Detect fraud count : 9 Percent of Detect fraud from total normal : 0.71%

모델 생성 및 검증 결과 전반적으로 90%이상의 높은 탐지율과 1% 미만의 낮은 오탐율을 보였으며, 고객의 과거 전자금융거래 패턴(프로파일링 분석 변

수)과 현재 이체거래시 나타나는 거래데이터(거래 변수)를 학습데이터로 DNN에 적용하여 수립한 이상거래탐지 모델이 이전에 연구되었던 모델의 성과를 뛰어넘는 결과를 보여주었다(그림6).

[그림6]기존FDS탐지율과의 비교



4. 2차 실험

4.1. 개요

1차 실험을 통해 DNN 학습을 통해 높은 수준의 전자금융이상거래탐지 모델의 수립이 가능함을 증명하였다. 하지만, DNN을 통해 생성된 모델의 경우 학습데이터 범주를 넘어서는 새로운 데이터에 대한 분류는 정확도가 하락하는 등 변화하는 미래에 능동적인 대응이 어렵다는 한계가 있다. 즉, 미래에 전자금융 이용환경이 변화됨에 따라 모델에 대입되는 데이터가 변화된다면 이상거래탐지 모델에도 변화가 필요하며 이에 대해 선제적으로 대응이 어렵다는 한계가 지적될 수 있다. 특히, 최근 금융감독당국에서는 인터넷뱅킹 서비스에 보안프로그램 설치 의무화를 폐지함⁵⁾에 따라 향후 전자금융 이용자 환경의 변화가 예상되고 있다.

2차 실험에서는 인터넷뱅킹 보안프로그램 폐지라는 예상되는 미래 변화에 맞추어 전자금융 거래로그 데이터 변화를 예측하고, 1차 실험에 사용되었던 데이터를 예측되는 변화에 맞게 가공하여 다시 한 번 학습을 통해 이상거래탐지모델을 수립하고 검증 하는 것으로 실험을 수행하였다. 이를 통해 미래의 변화를 예상할 수 있다면 그에 맞게 현재 데이터를 가공하여 미래에 대응 가능한 선제적인 이상거래탐지모델을 수립하고 검증하는 것이 가능함을 보이고자 하였다.

4.2. 실험데이터 정의

현재의 국내 인터넷뱅킹서비스 환경에서 별도의 추가적인 개발 없이 보안프로그램을 배제한다면, 인터넷뱅킹서비스 사용자의 OS식별정보, 네트워크 설정 정보, 브라우저정보를 수집할 수 없으므로 이와 관련한 학습데이터 변수 10개를 제외한 32개의 변수를 학습데이터의 input data로 재정의 하였다[표2].

[표2] 학습 데이터 변수 (2차실험)

Input 학습데이터 변수 정의				Output 변수 정의	
No.	변수명	No.	변수명	No.	변수명
1	int_device_cnt	11	multi_trans_tf	22	os_none
2	smt_device_cnt	12	transfer_account_cnt	23	china_ip_tf
3	ios_login_days	13	night_trans_cnt	24	new_ip_tf
4	ipad_login_days	14	nat_ip_cnt	25	multi_transfer_tf
5	android_login_days	15	cn_login_days	26	new_acc_tf
6	window_login_days	16	abroad_login_days	27	today_same_acc_tcnt
7	etc_login_days	17	card	28	today_same_acc_tamt
8	total_trans_cnt	18	otp	29	night_tf
9	total_trans_amt	19	os_ipad	30	select_device_tf
10	total_trans_days	20	os_ios	31	modify_info_tf
		21	os_window	32	transfer_amt

전자금융사고 해당 유무
(유=1, 무=0)를 정의

4.3. DNN설계

1차실험과 동일한 Topology로 모델1, 모델2, 모델3을 설계하였다.

4.4. 모델생성 및 검증

모델1, 모델2, 모델3을 각각 변경하여 새롭게 생성한 학습데이터를 40회 학습한 후 검증데이터를 대입하여 사고거래와 정상거래를 분류한 결과 모델1에서는 27건의 사고거래 중 22건을 탐지하여 81%의 탐지율을 달성하였으며, 정상거래 1,265건 중 4건을 사고거래로 탐지하여 0.32%의 오탐율을 보였다. 모델2에서는 27건의 사고거래 중 20건을 탐지하여 74%의 탐지율을 달성하였으며, 정상거래 1,265건 중 4건을 사고거래로 탐지하여 0.32%의 오탐율을 보였다. 모델3에서는 27건의 사고거래 중 18건을 탐지하여 66%의 탐지율을 달성하였으며, 정상거래 1,265건 중 1건을 사고거래로 탐지하여 0.08%의 오탐율을 보였다(그림7).

1차 실험결과 90%이상의 높은 탐지율과 비교하여, 2차 실험결과에서는 67%~81%로 비교적 낮은 사고거래 탐지율을 보였으며, 오탐율의 경우 0.5% 미만의 1차 실험결과에 비해 비교적 낮은 오탐율을 보였다. 이는 학습데이터에 사용도는 변수의 수가 42개에서 32개로 축소됨에 따라 정상거래와 사고거래를 분류하는 특징의 정확도가 낮아진 것으로 해석될 수 있다.

2차 실험 결과 탐지 정확도가 하락하였으나, 80%에 가까운 높은 탐지율을 보여줌으로써 보안프로그램이 없는 환경에서도 딥러닝을 통해 유의미한 이상거래탐지모델을 수립할 수 있음을 보였으며, 향후 HTML5 기술 등을 활용하여 보안프로그램에 대한 의존 없이 고객의 단말환경 정보를 추가로 수집한다면, 탐지율을 개선할 수 있을 것으로 보인다.

[그림7]전자금융이상거래탐지 모델 검증결과(2차 실험)

모델 1 검증결과	모델 2 검증결과	모델 3 검증결과
학습횟수 : 40회 batch_size : 10 사고탐지율 : 27건 중 22건 탐지 (81%) 사고오탐지율 : 1265건 4건 오탐 (0.32%) Total fraud count : 27 Detect fraud count : 22 Percent of Detect fraud from total fraud : 81.00% Total normal count : 1265 Detect fraud count : 4 Percent of Detect fraud from total normal : 0.32%	학습횟수 : 40회 batch_size : 10 사고탐지율 : 27건 중 20건 탐지 (74%) 사고오탐지율 : 1265건 4건 오탐 (0.32%) Total fraud count : 27 Detect fraud count : 20 Percent of Detect fraud from total fraud : 74.00% Total normal count : 1265 Detect fraud count : 4 Percent of Detect fraud from total normal : 0.32%	학습횟수 : 40회 batch_size : 10 사고탐지율 : 27건 중 18건 탐지 (66%) 사고오탐지율 : 1265건 1건 오탐 (0.08%) Total fraud count : 27 Detect fraud count : 18 Percent of Detect fraud from total fraud : 66.00% Total normal count : 1265 Detect fraud count : 1 Percent of Detect fraud from total normal : 0.08%

5. 결론 및 시사점

기존 연구는 거래로그 기반의 인공지능망을 활용 또는 프로파일링 기반의 데이터마이닝 분류 기법을 활용한 이상거래 탐지 모델 구축 및 효과에 대한 연구가 주를 이루고 있으며, 인터넷뱅킹 접속IP 대역, OS종류, 접속 시간대 등 10개 내외의 변수가 데이터 분석 및 모델 수립에 사용되었다.

그에 반하여, 이 번 논문에서는 국내 인터넷환경에서 요구되는 ActiveX 보안프로그램을 통해 수집되는 고객단말 환경 정보, 네트워크 정보 및 고객의 이체거래와 관련된 26가지의 거래 정보를 기반으로 하였으며, 과거 1년치 데이터를 대상으로 프로파일링 분석을 통해 전처리한 변수를 더하여 총 42개의 변수를 딥러닝 알고리즘 학습에 활용하여 모델을 생성하고 검증 하였다는데 의미가 있다.

이 번 논문의 가장 큰 기여는 딥러닝을 적용한 전자금융 이상거래탐지 모델을 통해 기존 룰기반 대비 높은 탐지율과 현격하게 낮은 오탐율을 달성 함으로써 딥러닝 기술이 국내 전자금융 이용자 보호를 위해 유의미하게 활용될 수 있음을 보여주었다는 것이며, 추가 실험을 통해 향후 국내 인터넷뱅킹에 예상되는 NonActiveX 환경에 맞추어 학습 데이터를 조작한 후 딥러닝 학습을 통해 선제적인 전자금융이상거래탐지 모델을 수립할 수 있음을 보여주었다는 점이다.

향후, 전자금융 환경에 ActiveX 등 보안프로그램이 없는 환경으로 변화가 예상되고 있으며, 새로운 환경에서도 딥러닝을 적용한 이상거래탐지 모델이 90% 이상의 사고탐지율을 달성 하기 위해서는 HTML5 및 javascript를 통한 고객의 PC환경 정보(화면해상도, 브라우저 버전 등) 추가 수집에 대한 검토가 필요할 것으로 보인다.

또한, 딥러닝 기술을 활용한 전자금융이상거래 탐지 체계를 구축하기 위해 기존 FDS를 버리고 전면적으로 딥러닝 기술을 도입하기 보다는 딥러닝 기술에 의한 모델을 하나의 새로운 룰로써 적용 가능하도록 FDS시스템에 추가적인 환경 구성을 하여, 룰기반 + 딥러닝 룰 과 같은 하이브리드 모델에 대한 적용 검토가 필요할 것으로 생각된다.

참고 문헌

- Golik, Pavel, Patrick Doetsch, and Hermann Ney, 'Cross-Entropy vs. Squared Error Training: a Theoretical and Experimental Comparison.' INTERSPEECH, 2013
- 최의순, '전자금융거래의 이상징후 탐지 규칙 개선을 통한 효과성 향상에 관한 연구', 고려대학교 2015.6
- 장재환, '인터넷뱅킹의 금융거래정보 분석을 통한 이상금융거래 탐지 기법', 중앙대학교 2012.2
- 박은영, 윤지원, '전자금융거래 이상징후 분석을 통한 사고예방 효과성에 관한 연구' 고려대학교 2014.11
- 박재훈, '의사결정나무를 이용한 이상금융거래 탐지 정규화 방법에 관한 연구' 고려대학교 2014.12
- Sanjeev Jha, 'Employing transaction aggregation strategy to detect credit card fraud' Expert Systems with Applications 2012
- Yann LeCun, Yoshua Bengio, Geoffrey Hinton, 'Deep learning' Nature 2015.5
- Nitish Srivastava, Geoffrey Hinton, 'Dropout: A Simple Way to Prevent Neural Networks from Overfitting' Journal of Machine Learning Research 15 2014
- Diederik P. Kingma, Diederik P. Kingma, 'ADAM: A METHOD FOR STOCHASTIC OPTIMIZATION' ICLR 2015

Abstract

Development of an online-banking-fraud-detect model based on Deep learning algorithm

Jeon, Il Kyo

Financial Information Privacy and Security

Graduate School of Information

Yonsei University

After 2010, the number of electronic banking user in Korea steadily increased with the arrival of smartphone. With the growth of online finance environment within a short period of time, online banking fraud accident like pharming, phishing also increased as well. Thus, in 2014 most of domestic banks in Korea started building and operating of rule based Fraud-detect-system(FDS) for detecting and controlling fraud transaction on online banking service.

Rule based FDS has showed effectiveness for prevention of online banking fraud accident. However, it also shows weakness in accuracy stems from the high rate of false fraud-detection which is actually not fraud

transaction.

So, this paper proposes a new method of developing fraud detection model focused on deep learning algorithm and using high quality of learning data set based on user profiling analytics.

The main result and contribution of this study is showing improvements on fraud detection rate and false detection rate of FDS based on deep learning model and also, showing a possibility of making preemptive fraud detection model by using deep learning algorithm with manipulated data adapted to future expected changes on online banking environment.

Key Words : deep learning, FDS, online-fraud, fraud detect model